



Gobernando Agentes de IA

La Perspectiva de HOLO sobre la Gobernanza
Agéntica Soberana

Copyright © 2026
HOLO SAS

Todos los derechos reservados

Documento de perspectiva · NEXXO C2 · Subsistema CD-FAT

Introducción

Los Agentes de Inteligencia Artificial (IA) son sistemas contruidos sobre Modelos Lingüísticos de Gran Escala (LLM) dotados de acceso a herramientas que les permiten ejecutar acciones en nombre de sus usuarios. Mientras que un LLM opera de forma reactiva —responde a las indicaciones que recibe—, el acceso directo e intencional de un Agente a herramientas externas habilita capacidades y acciones de naturaleza distinta, que traen consigo desafíos igualmente nuevos. En el ámbito de la defensa y la seguridad, estos sistemas prometen comprimir los ciclos de decisión, sintetizar volúmenes de información antes inabarcables y descargar al estado mayor de tareas rutinarias. Ya hoy se incorporan Agentes en plataformas institucionales para analizar datos, correlacionar inteligencia y recomendar cursos de acción a una escala que hace apenas un año resultaba difícil de imaginar.

Cuán bien se desempeñan estos Agentes en un entorno operacional, cuán seguros son y cuán confiables resultan, siguen siendo preguntas abiertas. Las pruebas de capacidad que publican los laboratorios de frontera son alentadoras: los modelos obtienen resultados cada vez mejores en una amplia gama de pruebas de referencia (benchmarks) agénticas, que ofrecen una indicación de base sobre cómo un Agente ejecuta funciones rutinarias en condiciones estándar. Sin embargo, esos resultados no se traducen automáticamente en desempeño dentro de entornos complejos, dinámicos y cargados de incertidumbre, como lo es el teatro de operaciones. Las salvaguardas que los laboratorios incorporan al nivel del modelo tampoco predicen un comportamiento seguro aguas abajo: se erosionan con rapidez cuando se introduce contexto específico mediante ajuste fino (fine-tuning), equipos rojos y otras formas de adaptar el modelo a un entorno especializado. La investigación disponible sugiere que los Agentes actuales no son lo bastante consistentes para aplicaciones críticas para la misión, y que las mediciones de laboratorio no anticipan su comportamiento en el mundo real.

Para comprender cómo se comportan los Agentes en contextos operacionales se requiere algo más que salvaguardas del modelo o benchmarks aguas arriba: se requiere infraestructura robusta de evaluación y gobernanza durante y después del despliegue. Gobernar Agentes de IA exige una base sólida —que comienza con controles para una supervisión efectiva y se completa con flujos de trabajo que confieren legibilidad sobre el funcionamiento del Agente a lo largo del tiempo—. Esta es la convicción que ordena el diseño de NEXXO C2 y, en particular, de su subsistema de gobernanza CD-FAT (Crosswalk Doctrinal Federado de Adopción Tutelada). Para las Fuerzas Militares de Colombia y, más ampliamente, para los Estados del Sur Global, esta base no es solo una cuestión técnica: es una condición de soberanía.

Las mejoras de capacidad no predicen el desempeño, la seguridad ni la confiabilidad en el mundo real

Las pruebas de referencia de modelos y de Agentes son útiles para medir capacidades en un laboratorio o un entorno controlado, pero no predicen el desempeño operacional, la seguridad ni la confiabilidad de los Agentes en entornos abiertos.

Desempeño operacional

Probar un modelo de frontera en un laboratorio no reproduce las condiciones reales en las que una capacidad de IA opera dentro de un sistema más amplio y de un contexto institucional. Al exponerse a datos, herramientas y situaciones ajenas al banco de pruebas, los modelos y Agentes embebidos en sistemas se comportan de manera distinta a como lo hacen en el laboratorio. En el contexto de la defensa, esa brecha se amplifica: los entornos de operación suelen ser DDIL —comunicaciones denegadas, degradadas, intermitentes o de ancho de banda limitado—; los datos están fragmentados entre niveles de clasificación; y el costo de un error no se mide en eficiencia perdida, sino en vidas y en responsabilidad jurídica. La experiencia de la industria con la integración de IA en entornos productivos—donde la inmensa mayoría de las organizaciones reporta tropiezos asociados a la calidad de los datos, la brecha de competencias del personal, la integración con sistemas heredados y la escalabilidad— anticipa, en su versión civil, los obstáculos que un teatro de operaciones agrava.

Seguridad

Los mecanismos de seguridad al nivel del modelo son insuficientes por sí solos. Implementar y mantener esas barreras una vez el sistema está desplegado en el entorno institucional es indispensable. La comunidad investigadora ha mostrado que basta un ajuste fino modesto para que un modelo abandone las salvaguardas que sus diseñadores incorporaron deliberadamente, y que el sometimiento a equipos rojos sigue una tendencia análoga. Estos hallazgos, que la investigación apenas comienza a dimensionar, se vuelven más agudos en entornos productivos complejos. La lección es la que otras disciplinas de ingeniería dan por sentada: las pruebas de seguridad en laboratorio son útiles pero insuficientes, y deben complementarse con una evaluación operacional. Cuanto más se emplean los LLM en producción, más claro resulta que los Agentes contruidos sobre ellos no son la excepción.

Confiabilidad

Otra brecha significativa entre el laboratorio y el entorno operacional es la falta de confiabilidad de los Agentes. Estudios en entornos controlados establecen que los avances recientes en capacidad agéntica han producido mejoras solo marginales en confiabilidad. Un Agente poco confiable puede ser aceptable en escenarios no críticos: una herramienta que falla el 1 % de las veces quizá baste para redactar correspondencia administrativa. Pero ese mismo margen de error es inadmisibles cuando el resultado alimenta un cuadro de mando para la toma de decisiones, sugiere la asignación de medios o incide sobre el empleo de la fuerza. El ámbito militar es —junto con el financiero y buena parte del sanitario— el caso paradigmático en el que no

saber cuándo fallará el Agente constituye un riesgo inaceptable. De ahí la necesidad de comprender a los Agentes en su contexto de despliegue, y no en el abstracto de un benchmark.

La difusión agéntica es gobernable

Ante estas limitaciones y la creciente adopción de Agentes, no falta quien advierta que estos sistemas —de desempeño operacional incierto, escasas salvaguardas y confiabilidad limitada— terminarán por desbordar y perturbar nuestras instituciones de forma incontrolable. Las capacidades de laboratorio mejoran a ritmo acelerado y organizaciones de todo tipo intentan adoptar IA agéntica para no quedar rezagadas. Pero cuando el panorama de riesgo se comprende mal, las estrategias para gestionarlo se comprenden aún peor, y tanto quienes adoptan como quienes tienen responsabilidades de supervisión corren el riesgo de asumir, equivocadamente, un juego de suma cero. La realidad es otra: la difusión efectiva de los Agentes avanza mucho más despacio que las mejoras de capacidad en el laboratorio, y esa observación se confirma en la adopción real y en la investigación emergente. Esa brecha entre la capacidad y el desempeño operacional es, precisamente, el espacio en el que la institución decide cuándo adoptar un Agente y dicta cómo se usa. Es el espacio de la gobernanza.

Para el Sur Global, esa brecha es además el espacio de la soberanía. La disyuntiva no es entre adoptar cajas negras extranjeras o quedar rezagado. La adopción de IA agéntica puede —y debe— hacerse de forma tutelada: a un ritmo que la institución controla, sobre una base doctrinal propia y con la capacidad de auditar, restringir y revertir lo que el Agente hace. Este es el principio que da nombre al subsistema CD-FAT de NEXXO C2: una Adopción Tutelada, en la que el Agente aumenta el juicio del estado mayor en lugar de sustituirlo.

Cómo se incorporarán los Agentes para mejorar de forma significativa los flujos de trabajo es algo que tomará tiempo resolver, y que corresponde decidir a la institución mediante el ejercicio del juicio humano. Como en el desarrollo de software tradicional, construir una versión demostrativa de un Agente puede ser rápido; construir uno robusto y sostenible, que produzca resultados confiables que se acumulen sobre lo que el operador necesita, es un proceso mucho más complejo y lento. Ese proceso determina cómo se construyen y despliegan realmente los Agentes y, como ocurre con casi toda tecnología, abre el espacio para superponer gobernanza sobre el sistema.

La gobernanza alcanza también al modo en que los humanos integran Agentes para trabajar como «equipos». La colaboración humano-Agente exige ajustes para determinar cómo entregar resultados de manera efectiva. Un operador asistido por IA puede superar a un operador solo, pero no siempre produce un resultado estrictamente mejor: depende del caso de uso, de la tarea y de cómo se optimice la colaboración —igual que al integrar a un nuevo miembro al estado mayor—. Encontrar dónde y cómo encajan los Agentes en el flujo de trabajo será, por tanto, un proceso prolongado; y es ahí donde una gobernanza deliberada orienta los resultados.

La infraestructura de gobernanza en la práctica

La brecha entre el desempeño, la seguridad y la confiabilidad de los Agentes en el plano teórico y en el mundo real es considerable. Esa brecha representa una oportunidad: la de comprender el desempeño agéntico en el contexto institucional y detectar cuándo los Agentes no producen los resultados esperados. Para ello se requiere una infraestructura de gobernanza robusta, orientada a la evaluación de los Agentes en su entorno de despliegue. Las capacidades que deben gobernar al sistema han de estar embebidas en el núcleo de su diseño, no añadidas después, de modo que el Agente sea legible y gobernable.

Distinguimos dos capas: los controles de gobernanza y los flujos de gobernanza. Los **controles de gobernanza** proveen los cimientos —las primitivas y herramientas— que hacen posible la supervisión. Los **flujos de gobernanza** se construyen sobre esos mecanismos para que los usuarios materialicen sus propósitos de gobierno. En NEXXO C2, esta arquitectura de dos capas se encarna en CD-FAT.

Presentamos estos elementos a partir de la experiencia de desplegar tecnología en instituciones para misiones críticas. Estas prácticas, que han de edificarse sobre los procesos de gobernanza ya existentes en los sistemas institucionales, deberían orientar la manera en que las autoridades abordan la supervisión y la regulación de los sistemas de IA.

Controles de Gobernanza

Un conjunto sólido de controles de gobernanza es el cimiento crítico de cualquier contexto en el que se desarrollen, desplieguen o empleen Agentes de IA. Que un Agente sea poderoso no significa que deba, por defecto, acceder a todos los datos ni ejecutar cualquier acción en cualquier sistema. Las decisiones sobre su acceso a datos y acciones corresponden a personas dentro de la institución —administradores, desarrolladores, oficiales de protección de datos y equipos de supervisión—. Garantizar que esas decisiones permanezcan de forma fiable en manos humanas exige que los controles de gobernanza estén incorporados al sistema por defecto, no añadidos después.

- **Flujos de autorización.** Definir qué puede acceder y qué acciones puede ejecutar tanto un usuario humano como un Agente es uno de los modos más claros de gobernar la difusión agéntica. Así como los datos sensibles de personal solo deben ser visibles para quien tiene necesidad de conocer, el acceso de un Agente debe restringirse según las normas de la institución: un Agente al servicio de la sección de inteligencia (S2/G2) podrá acceder a cierto acervo, mientras que otros no. NEXXO C2 implementa control de acceso basado en clasificación (CBAC), control basado en propósito que limita el uso de los datos al fin declarado en su recolección, controles que reflejan categorías de manejo obligatorio, y un mapeo de permisos a los roles del estado mayor (S1-S6 / G1-G6) conforme al principio de necesidad de conocer.

- **Ejecución acotada.** Dado que el desempeño agéntico es desigual y la confiabilidad sigue siendo limitada, un Agente solo debe estar autorizado a actuar dentro de un entorno delimitado, y eso comienza en la capa fundacional. Qué herramientas o APIs —internas y externas— puede invocar un Agente debe estar restringido por defecto, y todo permiso concedido debe decidirse de forma explícita por los desarrolladores y el equipo de seguridad. En entornos DDIL, la ejecución acotada incluye además modos de operación degradada que preservan el control de la institución aun cuando las comunicaciones fallan.
- **Pruebas y evaluación.** Medir el desempeño y la confiabilidad de un Agente en el contexto institucional exige infraestructura de prueba construida para entornos operacionales. Apoyarse únicamente en las pruebas de los laboratorios de frontera no aporta la visibilidad que la institución necesita. La evaluación debe soportar tanto interacciones de un solo turno como de múltiples turnos, y ha de ser accesible a los expertos de dominio y operadores —los oficiales que conocen las restricciones del contexto y saben qué significa «bueno»—.
- **Observabilidad.** Compilar y conservar un registro inmutable de las acciones del Agente es un mecanismo de gobernanza cuya importancia no puede exagerarse. Capturar en bitácoras de auditoría, telemetría y trazas de acción tanto los accesos y acciones humanas como las agénticas es esencial para mantener el control institucional. En el ámbito militar, esa trazabilidad es además condición de la rendición de cuentas ante el Derecho Internacional Humanitario y los Derechos Humanos: una bitácora de auditoría como fuente autoritativa de verdad es el instrumento que permite la revisión posterior y el deslinde de la responsabilidad de mando.
- **Modos a prueba de fallos.** Como contención ante fallas agudas, la institución debe diseñar y desplegar mecanismos para interrumpir flujos agénticos cuando se detecten fallas o se superen restricciones. Garantizar que existe una forma de «apagar» un flujo agéntico específico es una palanca de control indispensable para orquestar la gobernanza.

Flujos de Gobernanza

Mientras los controles de gobernanza aportan los elementos técnicos fundacionales, los flujos de gobernanza son los métodos, procesos, políticas y aplicaciones que permiten a los usuarios poner en práctica sus planes y monitorearlos de forma continua. Estos flujos, aun estando técnicamente fundamentados, requieren una cultura institucional que refuerce las normas para que constituyan un componente real de un régimen de gobernanza sofisticado.

- **Evaluación continua.** La evaluación no puede ser una actividad única previa al despliegue. Los Agentes deben evaluarse de forma continua frente a los casos de uso para los que fueron desplegados —en especial cuando el modelo ha sido ajustado—, para determinar si se comportan con la seguridad y la confiabilidad que el contexto exige. La retroalimentación humana sobre las salidas del Agente es la señal de mayor calidad disponible para detectar dónde falla, y debe

capturarse de forma sistemática. Esa captura debe estar embebida en el flujo de trabajo donde se usa el Agente —no en una herramienta aparte—, de modo que el costo de transacción de retroalimentar sea lo bastante bajo para que los operadores efectivamente lo hagan.

- **Colaboración humano-Agente.** A medida que la institución mide el desempeño y la confiabilidad en contexto operacional, puede decidir cuánta autonomía asignar al Agente. Por defecto, el Agente debe configurarse para sugerir acciones hasta que su papel y utilidad se comprendan con claridad; a medida que sugiere un número creciente de acciones, los usuarios, administradores y desarrolladores pueden determinar si cierto conjunto de acciones es apropiado para que el Agente las ejecute de forma automática. Como con el acceso a datos, algunas acciones poco consecuentes pueden automatizarse; otras no. La decisión depende también de si la acción es reversible. Este escalamiento gradual y reversible de la autonomía es la esencia de la Adopción Tutelada de CD-FAT: el Agente aumenta el juicio del mando, no lo reemplaza.
- **Desarrollo del ciclo de vida de la IA.** A medida que la institución despliega más Agentes, sus líderes y equipos de gobernanza necesitan herramientas para gestionar los casos de uso a escala. No se puede gobernar lo que no se ve: comprender dónde se está usando la IA es esencial. Estas capacidades incluyen inventariar y catalogar casos de uso, seguir su progreso a lo largo del ciclo de vida, verificar su adherencia a los requisitos de política y administrar su documentación. En NEXXO C2, este flujo se ancla en el crosswalk doctrinal federado: cada caso de uso se traza contra la doctrina vigente, de modo que la adopción tecnológica permanezca subordinada al cuerpo doctrinal de la institución.

Conclusión

Los Agentes de IA representan una oportunidad genuina de transformar la manera en que operan las instituciones de defensa —pero solo para quienes comprenden lo que un Agente hace en la práctica, y no apenas en el laboratorio—. Este momento de innovación exige un pensamiento riguroso sobre las pruebas operacionales y la evaluación posterior al despliegue, para distinguir dónde se generan los resultados deseados de dónde la IA introduce ineficiencias o riesgos. Si las autoridades quieren entender de verdad cómo los Agentes están moldeando el entorno estratégico, deben mirar el contexto operacional para separar lo real de la exageración.

Para los Estados del Sur Global, y para Colombia en particular, ese examen tiene una dimensión adicional: la gobernanza soberana sobre la IA agéntica no es solo una cuestión de seguridad, sino de autonomía estratégica. Construir políticas, legislación y regulación en torno a la idea de que la evaluación aguas abajo es una mejor medida del desempeño, la seguridad y la confiabilidad —y sobre una base doctrinal y tecnológica propia— ayudará a que las protecciones atiendan las áreas de riesgo más salientes y conserven su valor a medida que el panorama tecnológico siga

evolucionando. Esa es la convicción que HOLO incorpora en NEXXO C2: que la soberanía, en la era agéntica, se ejerce gobernando.

